

INFORME DE AUDITORÍA Y SANEAMIENTO DE DATOS: PROYECTO GREENMART

Departamento: Nexeus.BigData

Fecha: 7 de junio de 2026

1. Adquisición y Diagnóstico Preliminar

- **Adquisición de datos:** Se utilizó la función `pd.read_csv` para la carga inicial de los archivos. Este proceso garantiza la lectura eficiente de la fuente de datos para su posterior tratamiento.

```
# Para una mayor eficiencia en el analisis de datos y la deteccion de tipos utilizaremos la libreria pandas.  
import pandas as pd  
# A continuacion importamos el archivo en formato lectura.  
df=pd.read_csv('/content/drive/MyDrive/Proyectos Nexeus/greenmart_customers_products.csv')
```

- **Inspección Estructural:** Se realizó una auditoría de integridad utilizando `df.info()` y `df.isnull().sum()`. Este diagnóstico permitió realizar un inventario preciso de la estructura de la tabla, identificando tipos de datos y volúmenes de registros incompletos.

```
#Comprobamos en que columnas tenemos valores nulos con .isnull().  
display(df.isnull().sum())  
  
#Identificamos los duplicados exactos.  
print(f"\nNumero de registros duplicados: {df.duplicated().sum()}")  
  
#Estadísticas descriptivas para la identificación de valores atípicos.  
display(df.describe())
```

- **Diagnóstico de Calidad:** Se detectaron 700 registros con datos operativos críticos faltantes (fecha y cantidad) y duplicados exactos. Estos hallazgos confirmaron que, sin una intervención correctiva, las métricas de negocio derivadas no serían fiables.

	customer_id	customer_name	age	city	product_id	product_name	category	purchase_date	purchase_quantity	price_per_unit	total_spent
0	1	Ronald Miller	63.0	Wilsonstad	141	Granola	Vegetable	2024-10-21	1.0	13.33	13.33
1	2	Eric White	26.0	North Brianside	172	Organic Apples	Vegetable	2024-08-15	2.0	1.04	2.08
2	3	Joseph Wagner	59.0	Lake Derek	186	Granola	Dairy	2024-07-16	1.0	15.33	15.33
3	4	Elizabeth House	43.0	Cindyborough	110	Granola	Snack	2024-09-18	1.0	10.55	10.55
4	5	Shawn Warner	56.0	North Hannah	147	Fresh Milk	Snack	2024-10-09	1.0	12.25	12.25
0											
	customer_id	0									
	customer_name	722									
	age	722									
	city	722									
	product_id	0									
	product_name	0									
	category	0									
	purchase_date	722									
	purchase_quantity	708									
	price_per_unit	0									
	total_spent	708									

2. Metodología de Saneamiento

El proceso de limpieza se ejecutó siguiendo una estrategia de "embudo" para asegurar la calidad en cada etapa:

- **Eliminación de Redundancias:** Se aplicó `df.drop_duplicates()` para garantizar que cada transacción sea única.

```
#En cuanto a la limpieza empezaremos por eliminar duplicados en los registros con duplicates,
df=df.drop_duplicates()
```

- **Conversión y Tipificación:** Mediante `pd.to_datetime` y `pd.to_numeric`, se estandarizaron los tipos de datos, utilizando la técnica de *coerción* para aislar datos corruptos.

```
#Tenemos datos temporales por lo que tendremos que transformarlos de manera directa.
df["purchase_date"]=pd.to_datetime(df["purchase_date"])

#Haremos de hacer lo mismo con los datos numericos ya que se estarían tratando como texto.
df["age"]=pd.to_numeric(df["age"],errors="coerce")

df["purchase_quantity"]=pd.to_numeric(df["purchase_quantity"],errors="coerce")

df["price_per_unit"]=pd.to_numeric(df["price_per_unit"],errors="coerce")

df["total_spent"]=pd.to_numeric(df["total_spent"],errors="coerce")
```

- **Saneamiento de Registros:** Se eliminaron transacciones "huérfanas" (sin fecha ni cantidad), ya que carecían de valor transaccional. Para los datos descriptivos restantes (edad, ciudad, categoría), se aplicó una técnica de **imputación** utilizando la mediana para valores numéricos y etiquetas de categoría para valores nulos, preservando así la integridad de la muestra.

```
# Sustituimos los valores de edad faltantes mediante .fillna utilizando la mediana como referencia.
df['age'] = df['age'].fillna(df['age'].median())
```

- **Validación Financiera:** Se recalculó la variable `total_spent` aplicando la lógica `precio * cantidad` para corregir discrepancias registradas.

```
#Corregimos los totales aplicando la formula correcta
df.loc[diferencias, 'total_spent'] = df.loc[diferencias, 'purchase_quantity'] * df.loc[diferencias, 'price_per_unit']
```

3. Resultados de Validación Final

Tras el proceso de saneamiento, el conjunto de datos resultante cumple con los estándares de alta calidad requeridos por Nexeus.BigData:

- **Unicidad:** 0 registros duplicados.
- **Integridad:** 0 valores nulos.
- **Consistencia:** 100% de coherencia financiera en los cálculos de ingresos.

```
*** --- Verificación definitiva ---
Total de nulos: 0
Total de duplicados: 0
Archivo exportado exitosamente con 0 nulos y 0 duplicados.
Verificación de integridad final:
Total de valores nulos: 0
Total de duplicados: 0

Archivo exportado exitosamente en: /content/drive/MyDrive/Proyectos Nexeus/greenmart customers products CLEAN.csv
```

4. Suposiciones y Decisiones de Negocio

- **Revisión de casos excepcionales:** Se asumió que los valores extremos en compras representan clientes al por mayor. Por ello, se han conservado en el conjunto final para no sesgar el análisis de volumen de negocio.
- **Criterio de gestión de vacíos:** : Se priorizó la eliminación de registros incompletos frente a la imputación para evitar distorsiones en los informes de ventas.

5. Entregables Finales

1. **Archivo Fuente:** `greenmart_customers_products_CLEAN.csv` (listo para análisis).
2. **Notebook de Auditoría:** `Nexeus_Cleaning_Notebook.ipynb` (contiene la trazabilidad total del código).
3. **Validación Definitiva:** Se adjunta la prueba técnica que certifica la limpieza total del conjunto de datos.